

Examen partiel 2 - Vendredi 4 mai 2018 - Durée : 60 min*Aucun document, pas de téléphone, pas de calculatrice.*Nom : **SKETCH OF** Prénom : **The Solution** Signature :

Exercice 1 :	Exercice 2 :	Total /20 :
--------------	--------------	-------------

Exercise 1 (Classifieur Naïf de Bayes, ≈ 10 pts)

On considère un problème de classification binaire où l'étiquette de classe est notée $Y \in \{0, 1\}$ et chaque exemple d'entraînement X contient 2 attributs binaires $X_1, X_2 \in \{0, 1\}$. Dans ce problème, on admet que X_1 et X_2 sont conditionnellement indépendants étant donné Y , c'est-à-dire $\Pr_V(X_1, X_2|Y) = \Pr_V(X_1|Y)\Pr_V(X_2|Y)$, que les probabilités a priori sont $\Pr_V(Y = 0) = \Pr_V(Y = 1) = 0.5$, et que les probabilités conditionnelles sont :

$\Pr_V(X_1 Y)$	$X_1 = 0$	$X_1 = 1$
$Y = 0$	0.7	0.3
$Y = 1$	0.2	0.8

$\Pr_V(X_2 Y)$	$X_2 = 0$	$X_2 = 1$
$Y = 0$	0.9	0.1
$Y = 1$	0.5	0.5

La notation $\Pr_V(\cdot)$ indique qu'il s'agit de la vraie distribution des variables aléatoires. La distribution des variables aléatoires modélisée par le test naïf de Bayes sera notée $\Pr_{NB}(\cdot)$.

Le taux d'erreur d'un classifieur est la probabilité que le classifieur fournisse une prédiction incorrecte pour une observation donnée Z : si Y est la vraie étiquette et $Z = Z(X_1, X_2)$ est l'observation utilisée pour prendre une décision ($Z = X_1$, $Z = X_2$ ou $Z = (X_1, X_2)$ dans la suite de l'exercice) et si $\hat{Y}(Z)$ correspond à la classe prédite, alors le taux d'erreur est

$$\Pr_V(Y \neq \hat{Y}(Z)) = \sum_{x_1=0}^1 \sum_{x_2=0}^1 \Pr_V(X_1 = x_1, X_2 = x_2, Y = 1 - \hat{Y}(Z(x_1, x_2))).$$

1. Rappeler la règle de décision du Maximum A Posteriori (MAP) du test naïf de Bayes qui exploite uniquement l'attribut X_1 . Montrer que cette règle de décision nécessite uniquement de connaître la distribution conjointe $\Pr_{NB}(X_1, Y)$.

MAP Rule

Decide 0 if $\Pr_{NB}(Y=0|X_1=x_1) \geq \Pr_{NB}(Y=1|X_1=x_1)$

But $\Pr_{NB}(Y=i|X_1=x_1) = \frac{\Pr_{NB}(X_1=x_1|Y=i) \Pr_{NB}(Y=i)}{\Pr_{NB}(X_1=x_1)}$

So the MAP rule is equivalent to

Decide 0 if $\boxed{\Pr_{NB}(X_1=x_1|Y=0) \Pr_{NB}(Y=0)} \geq \boxed{\Pr_{NB}(X_1=x_1|Y=1) \Pr_{NB}(Y=1)}$

$= \Pr_{NB}(X_1=x_1, Y=0)$
 $\Pr_{NB}(X_1=x_1, Y=1)$

2. Écrire le test naïf de Bayes qui exploite uniquement l'attribut X_1 pour les 2 valeurs possibles de X_1 . Écrire les réponses dans le tableau suivant :

X_1	$\Pr_{NB}(X_1, Y = 0)$	$\Pr_{NB}(X_1, Y = 1)$	$\hat{Y}(X_1)$
0	$0.7/2 = 0.35$	0.1	0
1	$0.3/2 = 0.15$	0.4	1

Justifier vos calculs ci-dessous :

$$\begin{aligned}
 \Pr_{NB}(X_1 = 0, Y = 0) &= \Pr_{NB}(X_1 = 0 | Y = 0) \Pr_{NB}(Y = 0) \\
 &= \Pr_V(X_1 = 0 | Y = 0) \Pr_V(Y = 0) \\
 &= 0.7 \times \frac{1}{2} = 0.35
 \end{aligned}$$

3. Calculer le taux d'erreur p_1 du test naïf de Bayes qui exploite seulement X_1 .

$$\begin{aligned}
 p_1 &= \Pr_V(X_1 = 0, Y = 1) + \Pr_V(X_1 = 1, Y = 0) \\
 &= 0.1 + 0.15 = 0.25
 \end{aligned}$$

4. Écrire le test naïf de Bayes qui exploite uniquement l'attribut X_2 pour les 2 valeurs possibles de X_2 . Écrire les réponses dans le tableau suivant :

X_2	$\Pr_{NB}(X_2, Y = 0)$	$\Pr_{NB}(X_2, Y = 1)$	$\hat{Y}(X_2)$
0	0.45	0.25	0
1	0.05	0.25	1

Justifier vos calculs ci-dessous :

$$\begin{aligned}
 \Pr_{NB}(X_2 = 0, Y = 0) &= \Pr_V(X_2 = 0 | Y = 0) \Pr_V(Y = 0) \\
 &= 0.9 \times \frac{1}{2} = 0.45
 \end{aligned}$$

5. Calculer le taux d'erreur p_2 du test naïf de Bayes qui exploite seulement X_2 .

$$p_2 = 0.25 + 0.05 = 0.3.$$

6. Écrire le test naïf de Bayes pour les 4 configurations possibles de X_1, X_2 . Écrire les réponses dans le tableau suivant :

X_1	X_2	$\Pr_{NB}(X_1, X_2, Y = 0)$	$\Pr_{NB}(X_1, X_2, Y = 1)$	$\hat{Y}(X_1, X_2)$
0	0	0.315	$0.2 \times 0.5 \times 0.5 = 0.05$	0
0	1	$0.7 \times 0.1 \times 0.5 = 0.035$	$0.2 \times 0.5 \times 0.5 = 0.05$	1
1	0	$0.3 \times 0.9 \times 0.5 = 0.135$	$0.8 \times 0.5 \times 0.5 = 0.2$	2
1	1	$0.3 \times 0.1 \times 0.5 = 0.015$	$0.8 \times 0.5 \times 0.5 = 0.2$	1

Justifier vos calculs ci-dessous :

$$\begin{aligned}
 \Pr_{NB}(X_1=0, X_2=0, Y=0) &= \Pr_{NB}(X_1=0, X_2=0 | Y=0) \Pr_{NB}(Y=0) \\
 &= \Pr_{NB}(X_1=0 | Y=0) \Pr_{NB}(X_2=0 | Y=0) \Pr_{NB}(Y=0) \\
 &= p_Y(X_1=0 | Y=0) p_Y(X_2=0 | Y=0) p_Y(Y=0) \\
 &= 0.7 \times 0.9 \times \frac{1}{2} = \frac{0.63}{2} = 0.315
 \end{aligned}$$

7. Calculer le taux d'erreur $p_{1,2}$ du test naïf de Bayes qui exploite X_1 et X_2 .

$$\begin{aligned}
 p_{1,2} &= 0.05 + 0.035 + 0.135 + 0.015 \\
 &= 0.235
 \end{aligned}$$

8. On suppose maintenant créer un nouveau attribut X_3 qui est une copie déterministe de X_2 . Écrire le test naïf de Bayes pour les 8 configurations possibles de X_1 , X_2 et X_3 .

X_1	X_2	X_3	$\Pr_{NB}(X_1, X_2, X_3, Y = 0)$	$\Pr_{NB}(X_1, X_2, X_3, Y = 1)$	$\hat{Y}(X_1, X_2, X_3)$
0	0	0	$0.7 \times 0.9 \times 0.9 \times 0.5$	$0.2 \times 0.5 \times 0.5 \times 0.5$	0
0	0	1	$0.7 \times 0.9 \times 0.1 \times 0.5$	$0.2 \times 0.5 \times 0.5 \times 0.5$	0
0	1	0	$0.7 \times 0.1 \times 0.9 \times 0.5$	$0.2 \times 0.5 \times 0.5 \times 0.5$	0
0	1	1	$0.7 \times 0.1 \times 0.1 \times 0.5$	$0.2 \times 0.5 \times 0.5 \times 0.5$	1
1	0	0	$0.3 \times 0.9 \times 0.9 \times 0.5$	$0.8 \times 0.5 \times 0.5 \times 0.5$	0
1	0	1	$0.3 \times 0.9 \times 0.1 \times 0.5$	$0.8 \times 0.5 \times 0.5 \times 0.5$	1
1	1	0	$0.3 \times 0.1 \times 0.9 \times 0.5$	$0.8 \times 0.5 \times 0.5 \times 0.5$	1
1	1	1	$0.3 \times 0.1 \times 0.1 \times 0.5$	$0.8 \times 0.5 \times 0.5 \times 0.5$	1

Justifier (brièvement) vos calculs ci-dessous :

Just assume X_2 and X_3 are independent and do the same calculation as before

9. Calculer le taux d'erreur $p_{1,2,3}$ du test naïf de Bayes qui exploite X_1 , X_2 et X_3 .

$$\begin{aligned}
 p_{1,2,3} &= 0.2 \times 0.5 \times 0.5 + 0.7 \times 0.1 \times 0.5 \\
 &+ 0.8 \times 0.5 \times 0.5 + 0.3 \times 0.1 \times 0.5 \\
 &= 0.5 \times (0.1 + 0.07 + 0.4 + 0.03) = 0.3
 \end{aligned}$$

10. Pouvez-vous expliquer la différence entre le taux d'erreur $p_{1,2}$ basé sur (X_1, X_2) et le taux d'erreur $p_{1,2,3}$ basé sur (X_1, X_2, X_3) ?

The independence assumption is wrong
 Hence the Bayes test with $X_1, X_2 = X_3$ is
 worst than the Bayes test with just X_1 and X_2 .
 Some cases do not occur (exp: $X_1=0, X_2=0, X_3=1$).

Exercise 2 (Régression Logistique, ≈ 10 pts)

106 patients atteints par la grippe ont été hospitalisés. On note Y_k la variable indicatrice valant 1 si le patient k est décédé et 0 sinon. Un facteur de risque X_k a été relevé : $X_k = 1$ si le patient k a plus de 65 ans et $X_k = 0$ si la personne a 65 ans ou moins.

Le tableau de contingence résumant les données observées est donné ci-dessous :

	$Y = 0$	$Y = 1$	
$X = 0$	82	14	96
$X = 1$	3	7	10
	85	21	106

On note n_{ij} le nombre de patients tels que $X = i$ et $Y = j$ pour $i = 0, 1$ et $j = 0, 1$, soit $n_{00} = 82$, $n_{01} = 14$, $n_{10} = 3$ et $n_{11} = 7$.

Nous voulons utiliser un modèle de régression logistique pour modéliser le lien entre la variable Y et le facteur de risque X .

- Notons $P(X) = \Pr(Y = 1|X)$ la probabilité de décès connaissant le facteur de risque X . Décrire le modèle mathématique entre $P(X)$ et X sous la forme $\text{logit}(P(X)) = \dots$ où vous définirez la fonction "logit". Le coefficient associé à X sera noté a et le terme constant sera noté b .

$$\text{logit } P(X) = aX + b$$

$$\text{logit } (p) = \ln \frac{p}{1-p}$$

- Quelle est l'inverse de la fonction "logit(u)" pour $u \in]0, 1[$? Prouver le résultat annoncé.

$$\text{Let } u \in (0, 1) \text{ and } z \in \mathbb{R}$$

$$z = \text{logit}(u) = \ln \frac{u}{1-u}$$

$$\Leftrightarrow e^z = \frac{u}{1-u} \Leftrightarrow (1-u)e^z = u$$

$$\Leftrightarrow e^z = u(1 + e^z) \Leftrightarrow u = \frac{1}{1 + e^{-z}} = \sigma(z)$$

since $1 + e^z > 0$

- On note $p_0 = P(0)$ et $p_1 = P(1)$. Exprimer p_0 et p_1 en fonction de a et b .

$$\text{We have } P(X) = \sigma(aX + b)$$

$$p_0 = P(0) = \sigma(b) = \frac{1}{1 + e^{-b}}$$

$$p_1 = P(1) = \sigma(a + b) = \frac{1}{1 + e^{-a-b}}$$

4. Montrer que la log-vraisemblance $L(a, b)$ du modèle logistique s'exprime sous la forme

$$L(a, b) = -n_{00} \ln(1 + e^b) - n_{01} \ln(1 + e^{-b}) - n_{10} \ln(1 + e^{a+b}) - n_{11} \ln(1 + e^{-a-b}).$$

$$\begin{aligned} \mathcal{L}(a, b) &= \ln \mathbb{P}(Y=0 | X=0)^{n_{00}} + \ln \mathbb{P}(Y=0 | X=1)^{n_{10}} \\ &\quad + \ln \mathbb{P}(Y=1 | X=0)^{n_{01}} + \ln \mathbb{P}(Y=1 | X=1)^{n_{11}} \end{aligned}$$

$$\mathbb{P}(Y=0 | X=0) = 1 - \mathbb{P}(Y=1 | X=0) = 1 - p_0 = 1 - \frac{1}{1+e^{-b}} = \frac{1}{1+e^b}$$

$$\mathbb{P}(Y=0 | X=1) = 1 - p_1 = \frac{1}{1+e^{a+b}}$$

Donc

$$\begin{aligned} \mathcal{L}(a, b) &= -n_{00} \ln(1+e^b) - n_{01} \ln(1+e^{-b}) - n_{10} \ln(1+e^{a+b}) \\ &\quad - n_{11} \ln(1+e^{-a-b}) \end{aligned}$$

5. Calculer le gradient $\nabla L(a, b)$ de $L(a, b)$ par rapport au couple de variables (a, b) .

$$\frac{\partial \mathcal{L}(a, b)}{\partial a} = \left(-n_{10} \frac{e^{a+b}}{1+e^{a+b}} + n_{11} \frac{e^{-a-b}}{1+e^{-a-b}} \right) \quad \text{Note that it is the same term.}$$

$$\frac{\partial \mathcal{L}(a, b)}{\partial b} = -n_{00} \frac{e^b}{1+e^b} + n_{01} \frac{e^{-b}}{1+e^{-b}} - n_{10} \frac{e^{a+b}}{1+e^{a+b}} + n_{11} \frac{e^{-a-b}}{1+e^{-a-b}}$$

$$\nabla \mathcal{L}(a, b) = \begin{pmatrix} \frac{\partial \mathcal{L}(a, b)}{\partial a} \\ \frac{\partial \mathcal{L}(a, b)}{\partial b} \end{pmatrix}$$

6. Calculer \hat{a} et \hat{b} qui maximise $L(a, b)$ à partir du calcul du gradient de la question précédente.

\hat{a}, \hat{b} satisfy $\nabla L(\hat{a}, \hat{b}) = 0$

① $-n_{10} \frac{e^{\hat{a}+\hat{b}}}{1+e^{\hat{a}+\hat{b}}} + n_{11} \frac{e^{-\hat{a}-\hat{b}}}{1+e^{\hat{a}+\hat{b}}} = 0$

$$n_{10} \frac{e^{\hat{a}+\hat{b}}}{1+e^{\hat{a}+\hat{b}}} = n_{11} \frac{1}{1+e^{\hat{a}+\hat{b}}} \Rightarrow e^{\hat{a}+\hat{b}} = \frac{n_{11}}{n_{10}}$$

② $-n_{00} \frac{e^{\hat{b}}}{1+e^{\hat{b}}} + n_{01} \frac{e^{-\hat{b}}}{1+e^{\hat{b}}} = 0 \Rightarrow -n_{00} e^{\hat{b}} + n_{01} = 0$

$$\Rightarrow e^{\hat{b}} = \frac{n_{01}}{n_{00}}$$

$$\Rightarrow \hat{b} = \ln \left[\frac{n_{01}}{n_{00}} \right]$$

③ $e^{\hat{a}} = \frac{n_{11}}{n_{10}} \times \frac{n_{00}}{n_{01}} \Rightarrow \hat{a} = \ln \left[\frac{n_{11} n_{00}}{n_{10} n_{01}} \right]$

$$= \ln \left[\frac{n_{11}}{n_{10}} \right] - \hat{b}$$